



Tecnológico de Monterrey

Momento de Retroalimentación: Módulo 2

Implementación de una técnica de aprendizaje máquina con el uso de un framework

Ana Paula Moreno Frías | A01751886

21 de septiembre de 2026

Inteligencia Artificial Avanzada para la Ciencia de Datos

Profesor: Jorge Ramírez Uresti

Objetivo

El objetivo de esta actividad fue desarrollar un modelo de clasificación utilizando una biblioteca de aprendizaje máquina y aplicar las herramientas de configuración y evaluación proporcionadas por el framework.

Se utilizó RandomForestClassifier de Scikit-learn para predecir si un estudiante universitario obtiene una colocación laboral (Placement), a partir del dataset College Student Placement Dataset. El enfoque de esta implementación se centró en utilizar y configurar correctamente el algoritmo mediante el framework, así como evaluar su desempeño sobre datos que no fueron utilizados durante el entrenamiento.


Análisis de los datos

Para esta implementación se utilizó el College Student Placement Dataset. Antes de entrenar el modelo se realizó un análisis exploratorio del dataset, la revisión de la variable objetivo y la preparación de los datos, documentados en el notebook correspondiente.

El dataset contiene 10,000 observaciones y utiliza Placement como variable objetivo, donde 0 representa No Placement y 1 representa Placement. Durante el preprocesamiento se eliminó la variable College_ID, debido a que funciona únicamente como identificador de cada estudiante, y se codificaron a formato numérico (0/1) las dos variables de texto del dataset: Internship_Experience y Placement.

En el análisis exploratorio se identificó un desbalance en la variable objetivo, donde el 83.41% de las observaciones corresponde a No Placement y el 16.59% a Placement. Este hallazgo se retomó en la presente implementación principalmente para seleccionar las métricas utilizadas durante la evaluación del modelo.

En este reporte el análisis se enfoca principalmente en la separación de los datos, el diagnóstico de bias y varianza, la aplicación de regularización, y la implementación y evaluación de Random Forest mediante Scikit-learn.



Preprocesamiento

El preprocesamiento de los datos se enfocó en dejarlos listos para el algoritmo, sin modificar su distribución original, para poder enfocar esta entrega en el uso y configuración de Random Forest mediante Scikit-learn.

Se eliminó la variable `College_ID`, debido a que funciona únicamente como identificador de cada estudiante. También se codificaron a formato numérico (0/1) las variables `Internship_Experience` y `Placement`, ambas originalmente de tipo texto (Yes/No). A diferencia del dataset de tarjetas de crédito utilizado en la entrega anterior, en este caso no fue necesario agrupar categorías especiales, ya que las variables categóricas del dataset no presentan códigos adicionales o inconsistentes.

Posteriormente, se separaron las variables predictoras (X) de la variable objetivo (y). La separación de los datos en conjuntos de entrenamiento, validación y prueba se detalla en la siguiente sección.

No se aplicó normalización ni estandarización de las variables, debido a que Random Forest realiza las divisiones de los árboles mediante umbrales sobre cada característica y no requiere que las variables se encuentren en una misma escala.

Separación en conjuntos de entrenamiento, validación y prueba

A diferencia de la entrega anterior, donde solo se usó un split de entrenamiento y prueba, en esta implementación los datos se dividieron en tres conjuntos: entrenamiento (60%), validación (20%) y prueba (20%), de forma estratificada por clase. El conjunto de entrenamiento se utiliza para ajustar los modelos; el conjunto de validación se utiliza para diagnosticar bias y varianza, y para comparar el modelo antes y después de aplicar regularización; el conjunto de prueba se

reserva por completo y se utiliza una única vez, al final, para reportar el desempeño real del modelo ya ajustado.

El conjunto de entrenamiento quedó con 5,999 registros, el de validación con 1,999 y el de prueba con 2,002 (60% / 20% / 20% de un total de 10,000 estudiantes). La proporción de la clase Placement se mantuvo prácticamente igual en los tres conjuntos (16.59% en entrenamiento, 16.56% en validación y 16.63% en prueba), lo que confirma que la separación estratificada preservó adecuadamente el desbalance original.


Diagnóstico de bias, varianza y nivel de ajuste

Para diagnosticar el modelo, se entrenó primero un Random Forest intencionalmente sin regularizar (sin límite de profundidad, `min_samples_split=2`, considerando todas las variables en cada división), y se evaluó en entrenamiento y en validación (nunca en prueba, ya que en esta etapa el objetivo es diagnosticar y decidir ajustes, no reportar el desempeño final).

El diagnóstico se realizó con el siguiente criterio: el bias se midió a partir del desempeño del modelo sobre su propio conjunto de entrenamiento (un desempeño bajo en train, pese a tener capacidad suficiente, indica bias alto); la varianza se midió a partir de la brecha entre el desempeño en entrenamiento y en validación (una brecha grande indica varianza alta). A partir de ambos se determinó el nivel de ajuste: bias alto + varianza baja → underfit; bias bajo + varianza alta → overfit; bias bajo + varianza baja → buen ajuste (fit).

El modelo baseline obtuvo un accuracy y un F1-score de 1.0 tanto en el conjunto de entrenamiento como en el de validación, con una brecha train-validation de 0.0. Un resultado perfecto en ambos conjuntos, y no solo en entrenamiento, es un caso poco común y se investigó antes de aceptarlo como diagnóstico final, para descartar que se debiera a fuga de datos (alguna variable en X funcionando como copia directa de la variable objetivo) en lugar de a una generalización real del modelo.

Para esto se revisó la importancia de cada variable en el modelo baseline. La importancia resultó repartida entre cuatro variables, sin que ninguna concentrara de forma aplastante la decisión del modelo: CGPA (33%), Projects_Completed (29%), IQ (19%) y Communication_Skills (19%). El resto de las variables (Prev_Sem_Result, Academic_Performance, Internship_Experience y Extra_Curricular_Score) tuvieron una importancia cercana a cero, lo cual es consistente con lo observado en la matriz de correlación de la sección 7: Prev_Sem_Result está correlacionada en 0.98 con CGPA, por lo que el modelo usa una y ya no necesita la otra por ser redundante, y las demás ya habían mostrado una correlación prácticamente nula con Placement.



Al no encontrarse una variable dominante, se descarta la fuga de datos como explicación. El resultado perfecto se atribuye entonces a que el dataset, al ser de tipo sintético (generado para fines de práctica), fue construido con una relación muy cercana a determinística entre esas cuatro variables y Placement.

Con esto, el diagnóstico queda así: bias bajo, ya que el accuracy y el F1 en entrenamiento fueron de 1.0; varianza baja, ya que la brecha entre entrenamiento y validación fue de 0.0; y nivel de ajuste fit (buen ajuste), sin señales de underfitting ni de overfitting.

Implementación de Random Forest y aplicación de regularización

Para esta implementación se usó RandomForestClassifier de Scikit-learn. Con base en el diagnóstico de la sección anterior, se entrenó un segundo modelo aplicando regularización sobre la misma base de 200 árboles, para controlar su complejidad y ver si eso reducía la varianza.

El modelo se configuró con `n_estimators=200`, es decir, 200 árboles de decisión. Se usó esta cantidad para que varios árboles contribuyan a la predicción final y el resultado sea más estable que el de un solo árbol.

También se puso `max_depth=12`, que limita qué tan profundo puede crecer cada árbol, y `min_samples_split=10`, que exige que un nodo tenga al menos 10 observaciones antes de poder dividirse. Esto evita que los árboles hagan divisiones sobre grupos muy pequeños.

En `max_features` se usó "sqrt", así que en cada división el modelo solo considera la raíz cuadrada del total de variables disponibles. Esto hace que los árboles no usen siempre las mismas variables, lo cual le da más diversidad al conjunto.

Por último, `random_state=42` se fijó para que el modelo dé los mismos resultados cada vez que se corre.

Con el modelo configurado, se entrenó con `fit()` usando `X_train` y `y_train`, y se evaluó otra vez en entrenamiento y validación para comparar contra el modelo baseline sin regularizar.

Al comparar ambos modelos en el conjunto de validación, dieron exactamente el mismo resultado: accuracy y F1 de 1.0, con una brecha train-validation de 0.0 en los dos casos. La regularización no cambió nada porque no había varianza que reducir; el modelo baseline ya generalizaba perfectamente desde antes.

Aun así se dejó el modelo regularizado como el final. No porque haya mejorado el resultado, sino porque un modelo con restricciones es más seguro si en el futuro los datos no son tan perfectamente separables como los de este dataset.


Evaluación del modelo

Debido al desbalance previamente identificado entre las clases No Placement y Placement, el desempeño del modelo se analizó principalmente mediante el recall y el F1-score. Aunque accuracy permite conocer la proporción total de predicciones correctas, puede resultar poco representativa cuando una de las clases aparece con mayor frecuencia que la otra.

El recall se seleccionó como una de las métricas principales porque permite conocer qué proporción de los estudiantes que realmente obtuvieron Placement logra ser identificada correctamente por el modelo. En este problema, un falso negativo corresponde a un estudiante que realmente fue colocado, pero que el modelo clasifica como No Placement, por lo que esta métrica permite analizar directamente la capacidad del modelo para detectar la clase de interés.

Por otra parte, se utilizó F1-score para considerar conjuntamente precision y recall. Esta métrica permite evaluar el balance entre la capacidad de identificar estudiantes con Placement y la precisión de las predicciones realizadas para esta clase. Por esta razón, recall y F1-score fueron considerados como las métricas principales, mientras que accuracy y precision se utilizaron como información complementaria.

Finalmente, se generó una matriz de confusión sobre el conjunto de prueba para visualizar la cantidad de verdaderos positivos, verdaderos negativos, falsos positivos y falsos negativos obtenidos por el modelo final (el regularizado). Esta representación permite observar con mayor detalle los tipos de clasificación realizados y complementar la interpretación de las métricas.



Análisis de resultados

El modelo final obtuvo un accuracy de 99.90% sobre el conjunto de prueba. Dado el desequilibrio entre las clases (83.41% de No Placement contra 16.59% de Placement), esta métrica se interpreta junto con las demás para confirmar que el modelo también identifica correctamente a la clase minoritaria.

La precision fue de 100%: todos los estudiantes que el modelo clasificó como Placement realmente obtuvieron una colocación, sin falsos positivos. El recall fue de 99.40%, lo que significa que el modelo identificó correctamente a 331 de los 333 estudiantes que realmente pertenecían a la clase Placement, con solo 2 falsos negativos. El F1-score resultante fue de 99.70%.

Este resultado es ligeramente menor al 1.0 perfecto obtenido en entrenamiento y validación, lo cual es razonable: el conjunto de prueba nunca fue visto por el modelo durante el diagnóstico ni el ajuste de hiperparámetros, así que es la primera medición sobre datos completamente nuevos. Que la caída sea mínima, de 1.0 a 0.999, confirma que el diagnóstico de bias bajo y varianza baja obtenido en la sección anterior fue correcto: el modelo generaliza bien y no estaba sobreajustado a los conjuntos de entrenamiento y validación.

Conclusión

La implementación de Random Forest mediante Scikit-learn permitió desarrollar y configurar un modelo para la predicción de la colocación laboral de estudiantes universitarios, siguiendo un proceso completo de separación en entrenamiento, validación y prueba, diagnóstico de bias y varianza, y ajuste mediante regularización.

El diagnóstico inicial mostró que el modelo baseline, sin regularizar, presentó un bias bajo y una varianza baja, lo que correspondió a un nivel de ajuste de tipo fit, sin señales de underfitting ni de overfitting. Al revisar la importancia de las variables, se confirmó que este resultado no se

debía a una fuga de datos, sino a que el dataset tiene una relación casi determinística entre CGPA, Projects_Completed, IQ y Communication_Skills con Placement.

A partir de este diagnóstico se aplicó regularización (`max_depth=12`, `min_samples_split=10`, `max_features="sqrt"`), la cual no modificó el desempeño en validación, ya que no había varianza que reducir. Aun así, se conservó como modelo final por ser una versión más simple y con menor riesgo de sobreajuste ante datos que no sean tan perfectamente separables como los de este conjunto.

Finalmente, el modelo regularizado, evaluado una sola vez sobre el conjunto de prueba nunca antes utilizado, obtuvo un accuracy de 99.90%, un recall de 99.40% y un F1-score de 99.70%. Esto confirma que el proceso de separación en train/validation/test, el diagnóstico de bias-varianza y el ajuste mediante regularización permitieron construir un modelo con una estimación confiable de su capacidad de generalización, prácticamente igual de sólida en datos nuevos que en los de entrenamiento.