



Tecnológico de Monterrey

Momento de Retroalimentación: Módulo 2. Análisis y Reporte sobre el desempeño del modelo

Ana Paula Moreno Frías | A01751886

16 de septiembre del 2026

Inteligencia Artificial Avanzada para la Ciencia de Datos

Profesor: Jorge Ramírez Uresti

Objetivo

El objetivo de esta actividad fue desarrollar un modelo de clasificación utilizando una biblioteca de aprendizaje máquina y aplicar las herramientas de configuración y evaluación proporcionadas por el framework.

Se utilizó RandomForestClassifier de Scikit-learn para predecir si un estudiante universitario obtiene una colocación laboral (Placement), a partir del dataset College Student Placement Dataset. El enfoque de esta implementación se centró en utilizar y configurar correctamente el algoritmo mediante el framework, así como evaluar su desempeño sobre datos que no fueron utilizados durante el entrenamiento.


Análisis de los datos

Para esta implementación se utilizó el mismo conjunto de datos y preprocesamiento desarrollado previamente en la actividad de implementación de Random Forest sin framework. En dicho trabajo se realizó el análisis exploratorio del dataset, la revisión de la variable objetivo y la preparación de los datos antes del entrenamiento.

El dataset contiene 10,000 observaciones y utiliza Placement como variable objetivo, donde 0 representa No Placement y 1 representa Placement. Durante el preprocesamiento se eliminó la variable College_ID, debido a que funciona únicamente como identificador de cada estudiante, y se codificaron a formato numérico (0/1) las dos variables de texto del dataset: Internship_Experience y Placement. Posteriormente se realizó una separación estratificada utilizando 70% de los datos para entrenamiento y 30% para prueba. Estas decisiones de preprocesamiento se conservaron en esta implementación para trabajar bajo las mismas condiciones que en el ejercicio anterior.

De igual manera, en el análisis previo se identificó un desbalance en la variable objetivo, donde el 83.41% de las observaciones corresponde a No Placement y el 16.59% a Placement. Este hallazgo se retomó en la presente implementación principalmente para seleccionar las métricas utilizadas durante la evaluación del modelo.

Debido a que el análisis exploratorio y las decisiones de preprocesamiento fueron documentados con mayor detalle en la entrega anterior, en este reporte el análisis se enfoca principalmente en la implementación, configuración y evaluación de Random Forest mediante Scikit-learn.



Preprocesamiento

Durante esta implementación se utilizó el mismo conjunto de datos y el preprocesamiento realizado previamente en la actividad de implementación de Random Forest sin framework. Esto permite mantener las mismas condiciones de preparación de los datos y enfocar esta entrega en el uso y configuración del algoritmo mediante Scikit-learn.

Durante el preprocesamiento se eliminó la variable `College_ID`, debido a que funciona únicamente como identificador de cada estudiante. También se codificaron a formato numérico (0/1) las variables `Internship_Experience` y `Placement`, ambas originalmente de tipo texto (Yes/No). A diferencia del dataset de tarjetas de crédito utilizado en la entrega anterior, en este caso no fue necesario agrupar categorías especiales, ya que las variables categóricas del dataset no presentan códigos adicionales o inconsistentes.

Posteriormente, se separaron las variables predictoras (X) de la variable objetivo (y). Los datos se dividieron de manera estratificada utilizando 70% para entrenamiento y 30% para prueba, manteniendo una proporción similar de las clases `Placement` y `No Placement` en ambos conjuntos (83.41% / 16.59% en entrenamiento y prueba, respectivamente).

No se aplicó normalización ni estandarización de las variables, debido a que Random Forest realiza las divisiones de los árboles mediante umbrales sobre cada característica y no requiere que las variables se encuentren en una misma escala.

Finalmente, durante el análisis previo se identificó un desbalance en la variable objetivo, con 83.41% de observaciones correspondientes a No Placement y 16.59% a Placement. Este comportamiento se consideró posteriormente para la selección e interpretación de las métricas de evaluación del modelo.

Implementación de Random Forest

Para esta implementación se utilizó RandomForestClassifier de la biblioteca Scikit-learn. El uso del framework permite construir y entrenar el modelo Random Forest mediante una serie de hiperparámetros que controlan características como el número de árboles, su profundidad y la forma en que se realizan las divisiones.

El modelo fue configurado con `n_estimators=200`, por lo que el bosque está compuesto por 200 árboles de decisión. Se utilizó esta cantidad con el objetivo de contar con múltiples árboles que contribuyan a la predicción final y obtener un resultado más estable que el generado por un árbol individual.

También se estableció `max_depth=12` para limitar la profundidad máxima de los árboles y controlar su complejidad. De manera complementaria, `min_samples_split=10` establece que un nodo debe contener al menos 10 observaciones para poder realizar una nueva división, evitando que los árboles generen divisiones sobre grupos demasiado pequeños.

Para `max_features` se utilizó "sqrt", por lo que en cada división se considera únicamente la raíz cuadrada del número total de características disponibles. Esto permite introducir diversidad entre los árboles que forman el Random Forest, ya que no todos utilizan necesariamente las mismas variables para realizar cada división.

Finalmente, se estableció `random_state=42` para mantener la reproducibilidad del modelo. De esta manera, los procesos aleatorios utilizados durante su construcción pueden mantenerse consistentes entre diferentes ejecuciones bajo las mismas condiciones.

Una vez configurado el modelo, se utilizó el método `fit()` de Scikit-learn para entrenar el Random Forest con los conjuntos `X_train` y `y_train`. Posteriormente, mediante `predict()` se generaron las predicciones para `X_test`, manteniendo el conjunto de prueba separado del proceso de entrenamiento.


Evaluación del modelo

Debido al desbalance previamente identificado entre las clases No Placement y Placement, el desempeño del modelo se analizó principalmente mediante el recall y el F1-score. Aunque accuracy permite conocer la proporción total de predicciones correctas, puede resultar poco representativa cuando una de las clases aparece con mayor frecuencia que la otra.

El recall se seleccionó como una de las métricas principales porque permite conocer qué proporción de los estudiantes que realmente obtuvieron Placement logra identificar correctamente el modelo. En este problema, un falso negativo corresponde a un estudiante que realmente fue colocado, pero que el modelo clasifica como No Placement, por lo que esta métrica permite analizar directamente la capacidad del modelo para detectar la clase de interés.

Por otra parte, se utilizó F1-score para considerar conjuntamente precision y recall. Esta métrica permite evaluar el balance entre la capacidad de identificar estudiantes con Placement y la precisión de las predicciones realizadas para esta clase. Por esta razón, recall y F1-score fueron considerados como las métricas principales, mientras que accuracy y precision se utilizaron como información complementaria.

Finalmente, se generó una matriz de confusión para visualizar la cantidad de verdaderos positivos, verdaderos negativos, falsos positivos y falsos negativos obtenidos por el modelo. Esta representación permite observar con mayor detalle los tipos de clasificación realizados y complementar la interpretación de las métricas.



Matriz de confusión:

```
[[2503  0]
 [  3 495]]
```

Accuracy: 0.9990003332222592

Precision: 1.0

Recall: 0.9939759036144579

F1-score: 0.9969788519637462

Análisis de resultados

El modelo obtuvo un accuracy de 99.90%, lo que indica que clasificó correctamente casi la totalidad de las observaciones del conjunto de prueba. Sin embargo, dado el desequilibrio entre las clases, esta métrica se interpretó en conjunto con las demás para confirmar que el modelo también es capaz de identificar correctamente a la clase minoritaria (Placement).

La precision obtenida fue de 100%, lo que significa que todos los estudiantes que el modelo clasificó como Placement realmente obtuvieron una colocación (0 falsos positivos). Por otro lado, el recall fue de 99.40%, indicando que el modelo logró identificar correctamente a casi la totalidad de los estudiantes que realmente pertenecían a la clase Placement.

Este comportamiento también se observa en la matriz de confusión. El modelo identificó correctamente 2,503 casos de No Placement y 495 casos de Placement. Únicamente 3 estudiantes que realmente obtuvieron Placement fueron clasificados como No Placement, y no se presentaron falsos positivos.

Finalmente, se obtuvo un F1-score de 99.70%. Este resultado refleja un balance casi perfecto entre precision y recall, y muestra que el modelo tiene una capacidad muy alta para identificar correctamente ambas clases, a pesar del desbalance presente en el dataset.

Vale la pena señalar que un desempeño tan cercano al 100% también puede ser señal de que las variables académicas disponibles (en particular CGPA, Prev_Sem_Result y Communication_Skills, que en el análisis de correlación mostraron los coeficientes más altos con la variable objetivo, alrededor de 0.32) separan casi perfectamente a los estudiantes colocados de los no colocados en este dataset. Esto es consistente con la naturaleza del dataset, que parece haber sido construido de forma sintética con una relación muy determinística entre las características académicas y la colocación.

Conclusión

En conclusión, la implementación de Random Forest mediante Scikit-learn permitió desarrollar y configurar un modelo para la predicción de la colocación laboral de estudiantes universitarios. El uso del framework facilitó la construcción, entrenamiento y evaluación del modelo, además de permitir controlar su comportamiento mediante distintos hiperparámetros.

Los resultados muestran un accuracy de 99.90%, un recall de 99.40% y un F1-score de 99.70%, lo que evidencia que el modelo identifica de forma muy consistente tanto a los estudiantes colocados como a los no colocados. A diferencia de la entrega anterior con el dataset de tarjetas de crédito, en este caso el desbalance de clases no representó una limitación significativa para el desempeño del modelo.

La evaluación mediante recall y F1-score permitió analizar con mayor detalle el comportamiento del modelo frente al desbalance de las clases. En general, esta implementación permitió comprender la importancia de configurar adecuadamente un algoritmo dentro de un framework y seleccionar métricas de evaluación de acuerdo con las características del problema.